

Wie Transformer rechnen lernen

Grokking, Fourier-Kreise und mechanistische Interpretierbarkeit

Motivation

Können neuronale Netze *rechnen*?

Die Frage

$$37 + 58 = ? \quad (\text{mod } 113)$$

- › Ein winziger Transformer (1 Layer, 128 Dimensionen)
- › Bekommt nur Zahlenpaare und ihre Summe modulo 113
- › Lernt er **auswendig** – oder entdeckt er einen **Algorithmus**?

Neel Nanda et al. (ICLR 2023) haben den gelernten Algorithmus **vollständig reverse-engineered**.

Nanda, Chan, Lieberum, Smith, Steinhardt. "Progress Measures for Grokking via Mechanistic Interpretability."

ICLR 2023.

Grokking

Plötzliches Verstehen – nach langem Auswendiglernen

Was ist Grokking?

- Modell lernt Trainingsdaten **sofort** auswendig
(100% Train-Accuracy nach wenigen Epochen)
- Test-Accuracy bleibt **lange bei 0%**
- Nach tausenden weiteren Epochen:
plötzlich **perfekte Generalisierung**
- Benannt nach Robert Heinlein:
“to grok” = tiefes Verstehen




*Bild: Train/Test
Accuracy Kurve
(Figure 2 aus Nanda et al.
2023)*

Quelle: Paper Fig. 2

Power et al. 2022 (Erstentdeckung); Nanda et al. 2023 (Erklärung)

Grokking – die drei Phasen



- **Überraschung:** Der Algorithmus ist *längst fertig*, bevor die Test-Accuracy springt!
- Weight Decay entfernt dann die Memorisierung ⇒ plötzlicher Sprung

Das Setup

Ein winziger Transformer

Das Experiment



Architektur:

- › $P = 113$ (Primzahl)
- › $d_{\text{model}} = 128$
- › 4 Attention Heads
- › 512 MLP-Neuronen, ReLU

Training:


- › 30% aller 113×113 Paare
- › AdamW, Weight Decay $\lambda = 1$
- › 40.000 Epochen
- › Kein LayerNorm

Der Algorithmus

Addition als Rotation auf einem Kreis

Die Kernidee in einem Satz

Das Netzwerk wandelt **Addition**
in **Rotation auf einem Kreis** um.



Jede Zahl t wird auf einen **Winkel** $\omega_k \cdot t$ auf dem Einheitskreis abgebildet.

Die Formel – Überblick

$$\text{Logit}(c \mid a, b) = \sum_{k \in \mathcal{K}} \alpha_k \cdot \cos\left(\frac{2\pi k (a + b - c)}{113}\right)$$

- $\mathcal{K}$ = wenige “Schlüssel­frequenzen” (z. B. 5 Stück)
- α_k = gelernte Amplitude
- Wenn $c = (a + b) \bmod 113$: alle Cosinus = 1 $\Rightarrow$ **Maximum**
- Wenn $c \neq (a + b) \bmod 113$: verschiedene Richtungen $\Rightarrow$ **Auslöschung**


Konstruktive Interferenz am richtigen Ergebnis,
destruktive Interferenz überall sonst.

Schritt für Schritt

Wie der Transformer rechnet

Schritt 1: Embedding – Zahlen werden zu Kreispunkten


- › Jede Zahl $t \in \{0, \dots, 112\}$ wird eingebettet
- › Die Embedding-Matrix W_E ist **sparse im Fourier-Raum**
- › Effektiv kodiert sie:
 $\cos(\omega_k \cdot t)$ und $\sin(\omega_k \cdot t)$
für wenige Frequenzen k
- › $\omega_k = \frac{2\pi k}{113}$



Frequenz $k = 14$

Jede Zahl $\rightarrow$ ein Punkt auf dem Kreis. Verschiedene Frequenzen $\rightarrow$ verschiedene Kreise.


Wie die Kreise entstehen



Dieselben 113 Zahlen – auf verschiedenen Kreisen

- Jede Frequenz k erzeugt einen **eigenen Kreis**
- Zahl t sitzt bei Winkel $\omega_k \cdot t = \frac{2\pi k \cdot t}{113}$
- Höhere Frequenz $\rightarrow$ schnellere Rotation $\rightarrow$ andere Nachbarschaften

Schritt 2: Attention – Information zusammenführen



- Attention bewegt Fourier-Komponenten von a und b zur Position “=”
- Softmax über 2 Positionen $\approx$ Sigmoid $\approx$ **linear**
- Erzeugt **Produkte**: $\cos(\omega_k a) \cdot \cos(\omega_k b)$, etc.

Schritt 3: MLP – die trigonometrische Identität

$$\cos(\omega_k(a + b)) = \cos(\omega_k a) \cos(\omega_k b) - \sin(\omega_k a) \sin(\omega_k b)$$

- Die 512 ReLU-Neuronen berechnen **kollektiv** diese Identität
- ReLU = stückweise linear $\Rightarrow$ kann Produkte approximieren
- Ergebnis: $\cos(\omega_k(a + b))$ und $\sin(\omega_k(a + b))$
- Über 90% der Varianz erklärt!

Aha! Das Netz hat die Additionsformel aus der Schule *selbständig entdeckt* – ohne sie je gesehen zu haben.


Schritt 4: Unembedding – Ablesen des Ergebnisses

- Die Neuron-Logit-Matrix $W_L = W_U W_{\text{out}}$ ist **approximativ Rang 10**
- 5 Frequenzen $\times 2$ ($\cos + \sin$) = 10 Richtungen
- Für jedes mögliche Ergebnis c wird berechnet:

$$\text{Logit}(c) = \sum_{k \in \mathcal{K}} \alpha_k \left[\cos(\omega_k c) \cdot \cos(\omega_k (a+b)) + \sin(\omega_k c) \cdot \sin(\omega_k (a+b)) \right]$$


$$= \sum_{k \in \mathcal{K}} \alpha_k \cos(\omega_k (a + b - c)) \quad (\text{Cosinus-Subtraktionsidentität})$$

Schritt 5: Konstruktive Interferenz




- Bei $c = (a + b) \bmod 113$: **alle** Cosinus = 1 $\Rightarrow$ scharfes Maximum
- Bei jedem anderen c : verschiedene Phasen $\Rightarrow$ gegenseitige Auslöschung
- Wie bei Wellen im Wasser: Überlagerung verstärkt oder löscht aus

Warum mehrere Frequenzen?



1 Frequenz: Nebenpeaks!



5 Frequenzen: ein scharfer Peak!

- Eine Frequenz allein hat **Nebenpeaks** (fast so hoch wie das Maximum)
- Mehrere Frequenzen: Nebenpeaks liegen an **verschiedenen Stellen**
- $\Rightarrow$ Sie löschen sich gegenseitig aus, nur bei $c = a + b$ bleiben alle hoch

Zusammenfassung

Der vollständige Algorithmus

Der Algorithmus auf einen Blick



$$\text{Logit}(c) = \sum_{k \in \{14, 35, 41, 42, 52\}} \alpha_k \cos\left(\frac{2\pi k(a+b-c)}{113}\right)$$

Bei $c = (a + b) \bmod 113$: alle Cosinus = 1 $\Rightarrow$ **Maximum**

Bei $c \neq (a + b) \bmod 113$: destruktive Interferenz $\Rightarrow$ **klein**

Nanda et al. 2023, Table 1: FVE > 93% für alle Frequenzen

Evidenz

Wie wissen wir, dass das stimmt?

Evidenz: Periodizität überall



*Bild: Fourier-Komponenten
von W_E*

(Figure 3 links aus dem Paper)

Zeigt Sparsity: nur 5 Frequenzen




*Bild: Neuron-Aktivierungen
(Figure 4 Mitte aus dem Paper)*

Periodische Muster in Neuronen

- Embedding-Matrix W_E : **sparse** im Fourier-Raum – nur 5 Frequenzen
- Neuron-Aktivierungen: **periodisch** in den Eingaben
- Logits: nur 20 signifikante Fourier-Komponenten (5 Freq $\times$ 2 $\times$ 2)

Evidenz: Ablationen bestätigen den Circuit




- Alles außer den 5 Key-Frequenzen entfernen $\Rightarrow$ **Performance verbessert sich!**
- Die 5 Key-Frequenzen entfernen $\Rightarrow$ **schlechter als Zufall**
- $\Rightarrow$ Der Circuit ist **notwendig und hinreichend**

Analogie

Selbständiges Lernen von Zusammenhängen

Analogie: Geografie lernen

- › Gurnee & Tegmark (2023): LLMs lernen **Weltkarten**
- › Nie explizit trainiert – emergiert als **beste Kompression** der Daten
- › Ähnlich wie hier: das Netz entdeckt **Kreise** als beste Repräsentation für modulare Arithmetik
- › In beiden Fällen: das System lernt **geometrische Strukturen** eigenständig




Weltkarte aus 2 Dimensionen
eines LLM-Embedding-Raums

Gurnee, Tegmark. arXiv:2310.02207 (2023)

Kreise hier – Karten dort

Das System lernt **eigenständig** die geometrische Struktur,
die am besten zu den Daten passt.

Modulare Addition



Kreise (Fourier)

Sprache / Geografie



Mannigfaltigkeiten


- Die **konkreten Distanzen** sind nicht so wichtig
- Entscheidend: die **Proportionen** und **topologische Struktur** stimmen

Ausblick

Ein kleiner Circuit – viele weitere

Einordnung: Ein winziger Baustein

Großes Sprachmodell (z. B. GPT-4)



- Was wir gesehen haben: **ein sehr kleiner, möglicher Circuit**
- Große Modelle haben **hunderte bis tausende** solcher Circuits
- Jeder für eine andere Aufgabe: Grammatik, Logik, Fakten, ...

Was wir gelernt haben

1. **Grokking:** Plötzliche Generalisierung nach langem Auswendiglernen
2. **Fourier-Kreise:** Addition wird zu Rotation auf dem Einheitskreis
3. **Konstruktive Interferenz:** Mehrere Frequenzen erzeugen scharfe Peaks
4. **Eigenständiges Lernen:** Das Netz entdeckt Geometrie ohne Anleitung
5. **Topologie:** Proportionen zählen, nicht absolute Distanzen

Mechanistische Interpretierbarkeit ermöglicht es uns,
in die Black Box hineinzuschauen – Circuit für Circuit.

Nanda et al. 2023; Cammarata et al. 2020; Olsson et al. 2022

Danke!

Fragen?

Paper: Nanda et al. "Progress Measures for Grokking
via Mechanistic Interpretability" (ICLR 2023)

Code: neelnanda.io/grokking-paper