

Wie funktioniert ChatGPT wirklich?

Von einfachen Bausteinen zu künstlicher Intelligenz

Embeddings Recap


Wörter sind Punkte im Raum

Zur Erinnerung:

- Jedes Wort = ein Punkt
- Ähnliche Bedeutung = nah beieinander
- Hunderte Dimensionen

Die Achsen haben oft interpretierbare Bedeutungen!

Jetzt: Was passiert mit diesen Punkten weiter?




Tokenization

Wie liest die KI Text?


Die KI liest in **Tokens**: häufige Silben und Wortteile.

“unhappiness”



- Ca. 50k–100k verschiedene Tokens
- Häufige Wörter = 1 Token
- “Strawberry” → [Str][aw][berry]
- Die KI sieht keine Buchstaben!


Jedes Token wird zum Punkt



+ **Positional Encoding:** Jeder Punkt bekommt seine Position im Satz dazu

Positional Encoding: Wo bin ich im Satz?

Gleiches Wort, andere Position → anderer Punkt!



Das Encoding nutzt Sinus/Cosinus-Wellen verschiedener Frequenzen – wie eine Spirale, die jeder Position einen einzigartigen “Fingerabdruck” gibt.

Dense Layer und ReLU


Baustein 1: Das Dense Layer

Ein Neuron = eine einfache
Rechnung:

Eingabe: $x = 3$

Gewicht: $w = 0.5$, Bias: $b = -1$

$$y = w \cdot x + b = 0.5 \cdot 3 + (-1) = 0.5$$



Das ist nur eine **Gerade!**

Die Lösung: ReLU – Nichtlinearität!

ReLU = “Alles unter Null abschneiden”



Das erzeugt einen



Knick!

Und Knicke sind
der Schlüssel.


$$\text{ReLU}(x) = \max(0, x)$$

Demo: 2 Neuronen, 2 Layer


Netzwerk:



Neuron 1 nach ReLU




Neuron 2 nach ReLU




Summe: 2 Knicke!

Jedes Neuron fügt einen möglichen Knick hinzu.


Mehr Neuronen = Jede Funktion



2 Neuronen




8 Neuronen



1000+ Neuronen
 $\approx$ alles!

Universal Approximation: Dense + ReLU + Dense
kann jede Funktion beliebig genau nachbilden.

Beispiel: Bewässerung und Ernte



Das Netzwerk lernt:

- Mittags schlecht (Tropfen = Linse)
- Nachts schlecht (Schnecken)
- Morgens/Abends gut

Aber es “versteht” nichts:

- Kein Modell von Schnecken
- Kein Modell von Optik
- Nur: “hier geht’s, hier nicht”

Der Transformer

Wie wird daraus eine KI?

Wir brauchen zwei Bausteine:

Dense + ReLU

Punkte verschieben

+


Attention

Wörter verbinden


= Ein Transformer-Layer

(plus Normalisierung und Residual-Verbindungen
– Hilfsmittel die das Training stabilisieren)


Was ist ein Layer?



Gestapelt:



Was macht ein Layer mit den Punkten?



- **Attention** hat “Katze” und “sitzt” näher zusammengebracht (sie gehören zusammen)
- **Dense+ReLU** hat die Punkte weiter verschoben basierend auf dem neuen Kontext

Attention

Attention: Jedes Wort schaut alle anderen an




0.30

0.55

“saß” fragt: **Wer** hat gegessen? **Wo?**

Und bekommt Info von “Katze” und “Matte”

Attention: Query, Key, Value



Attention berechnet aus jedem Token-Embedding diese drei Vektoren.


Dann: $\text{Query} \times \text{Key} = \text{"Wie relevant bist du für mich?"}$

Hohe Relevanz $\rightarrow$ Value fließt ein.

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{Q \cdot K^T}{\sqrt{d}}\right) \cdot V$$


(Die Formel ist nur ein gewichtetes Mitteln – nichts Magisches!)

Frühe Layer: Tokens zusammenfügen




Attention erkennt: "Diese Tokens gehören zu einem Wort!"

Spätere Layer: Immer abstrakter



Jeder Layer = Attention + Dense. Frühe Layer sind noch verständlich.
Späte Layer? Da wird es mysteriös.

Nebeneffekt: “nicht gut” $\neq$ “schlecht”




Attention bildet **gewichtete Summen** – es mittelt zwischen Punkten. “nicht” verschiebt “gut” nur leicht. Es gibt keinen “spring zum Gegenteil”-Mechanismus.

Das ist eines von vielen Beispielen, wo die Architektur Grenzen setzt: Negation, Zählen, exakte Logik – alles schwierig für gewichtete Mittelwerte.

Next-Token-Prediction

Am Ende: Welches Wort kommt als nächstes?

Input: "Die flauschige ___"



Sampling: Zufall und Kontrolle


Temperature:

- Niedrig: Fast immer Top-Wort
- Hoch: Auch Überraschungen


Top-K:

- Nur die besten K Wörter
- Rest wird ausgeschlossen
- Verhindert Unsinn

Temp niedrig:



Temp hoch:



Beides zusammen steuert wie “kreativ” vs. “zuverlässig” die KI antwortet.

Die Black Box

Das große Geheimnis



Wir kennen jeden Baustein. Wir kennen jedes Gewicht.

Aber wir verstehen nicht, was die Gewichte zusammen bedeuten.

Wie ein Gehirn: Wir kennen die Neuronen, aber nicht die Gedanken.

Mechanistic Interpretability

Ein junges Forschungsfeld versucht,
die gelernten Algorithmen zu entschlüsseln.

Die Idee:

- Einzelne “Schaltkreise” finden
- Verstehen was wo gespeichert ist
- Algorithmen identifizieren


Stand heute:

- Ein verschwindend geringer Teil ist verstanden
- Aber: faszinierende Funde!
- Es funktioniert “gut genug”
– wir sehen nur nicht warum

Faszinierende Entdeckungen

Die Weltkarte im Netzwerk

Städte-Embeddings aus einem LLM



Das Modell hat **nie eine Karte gesehen**. Nur Text.
Aber die effizienteste Art Entfernungen zu kodieren *ist* eine Karte.

Modular Addition: Das Netzwerk erfindet Mathe


Experiment:

Trainiere ein kleines Netzwerk auf:

$$(a + b) \bmod 113$$


Was Forscher im Inneren fanden:

- Es stellt Zahlen als **Punkte auf einem Kreis** dar
- Addition = Rotation




Weitere Visualisierungen

[Hier: Bilder aus der Forschung]




Attention
Heatmap

BertViz / jessevig



Neuron
Features

Anthropic Blog



Grokking
Kurve

Neel Nanda et al.

Was wir wissen – und was nicht

Verstanden:

- Die Architektur (Bauplan)
- Einzelne einfache Schaltkreise
- Dass Struktur emergiert
- Dass es “irgendwie funktioniert”

Nicht verstanden:

- Was in den mittleren Layern passiert
- Warum Halluzinationen entstehen
- Ob es ein “Weltmodell” gibt
- Wie Reasoning wirklich funktioniert

Wir sehen, dass es funktioniert.

Wir verstehen einen verschwindend geringen Teil davon.

Zusammenfassung

Der komplette Weg

Text $\rightarrow$ Tokens (Silben-Stücke)

Tokens $\rightarrow$ Punkte im $\uparrow$ Raum (+ Position)

Attention: Punkte $\uparrow$ schauen sich gegenseitig an
 $\downarrow$

Dense+ReLU: Punkte werden verschoben
 $\downarrow$

Wiederhole Attention+Dense viele Male
 $\downarrow$

Letzter Punkt $\rightarrow$ Vergleich $\rightarrow$ nächstes Wort

Erstaunlich einfache Bausteine. Erstaunlich komplexes Ergebnis.

Was wir mitnehmen

1. **Tokens:** KI liest in Silben-Stücken
2. **Dense + ReLU:** Kann mit genug Neuronen alles berechnen
3. **Attention:** Lässt Wörter miteinander kommunizieren
4. **Layer:** Frühe = einfach, späte = abstrakt und mysteriös
5. **Vorhersage:** Immer nur das nächste Wort
6. **Emergenz:** Weltkarten, Mathe-Algorithmen entstehen von selbst
7. **Black Box:** Wir verstehen fast nichts vom Innenleben – noch nicht

Danke!

Fragen?