

Wie funktioniert ChatGPT wirklich?


Von einfachen Bausteinen zu künstlicher Intelligenz

Der Embedding Space

Wörter sind Punkte im Raum


- Jedes Wort = ein Punkt
- Ähnliche Bedeutung = nah beieinander
- Hunderte Dimensionen

**Die Achsen haben
manchmal
interpretierbare
Bedeutungen!**



Übersetzung im Embedding Space

Übersetzung $\approx$ Rotation + Verschiebung




Die **gleiche geometrische Struktur** existiert in beiden Sprachen –

Dense Layer und ReLU


Baustein 1: Das Dense Layer

Ein Neuron = eine Gerade:

$$y = w \cdot x + b$$




Egal wie viele Neuronen – linear
bleibt linear.



Nur eine Gerade.
Langweilig!


Die Lösung: ReLU – der Knick!




Der Knick
ist der
Schlüssel!

$$\text{ReLU}(x) = \max(0, x)$$


Mehr Knicke = Jede Funktion



2 Neuronen
1 Knick




8 Neuronen
viele Knicke



1000+ Neuronen
 $\approx$ **alles!**

Universal Approximation: Dense + ReLU
kann jede Funktion beliebig genau nachbilden.

Beispiel: Bewässerung und Ernte



Das Netzwerk lernt:

- Mittags schlecht (Verdunstung)
- Nachts schlecht (Schnecken)
- Morgens/Abends gut

Aber es “versteht” nichts:


- Kein Modell von Schnecken
- Kein Modell von Optik
- Nur: “hier geht’s, hier nicht”

Optimiert wird auf: Gewicht der Ernte am Ende

Tokenization


Wie liest die KI Text?

Die KI liest in **Tokens**: häufige Silben und Wortteile.



- Ca. 50k–100k verschiedene Tokens
- "Strawberry" → [Str][aw][berry]

Jedes Token wird zum Punkt im Embedding Space



Nachschlagen in einer Tabelle mit $\sim 100k$ Einträgen

Positional Encoding

Positional Encoding: Wo bin ich im Satz?

Gleiches Wort, andere Position → anderer Punkt!



[GRAFIK: Sinus/Cosinus-Wellen verschiedener Frequenzen]

Jede Position bekommt einen einzigartigen "Fingerabdruck"
aus überlagerten Wellen – wie ein Barcode für die Stelle im Text.

Der Transformer

Wie wird daraus eine KI?

Wir brauchen zwei Bausteine:

Attention

Wörter verbinden



Dense + ReLU

Punkte verschieben

= Ein Transformer-Layer


Davon stapelt man **viele** übereinander (z.B. 96 bei GPT-4).

Der Residual Stream: Das globale Notizbuch

Residual Stream

Jeder Layer
liest aus dem
Stream und
addiert sein
Ergebnis dazu.

Wie ein
**gemeinsames
Notizbuch.**



Attention

Attention: Long-Distance Dependencies

Ein Wort am Anfang kann die Bedeutung
eines Wortes am Ende bestimmen:

Wer kam?



Woher?

Attention erlaubt **direkte Verbindungen** über beliebige Distanzen.
Ohne Attention müsste Information Wort für Wort weitergereicht werden.

Attention: Query, Key, Value

Query

“Was suche ich?”

Key

“Was biete ich?”

Value

“Mein Inhalt”

Query $\times$ Key = “Wie relevant bist du für mich?”


Hohe Relevanz $\rightarrow$ Value fließt ein.

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{Q \cdot K^T}{\sqrt{d}}\right) \cdot V$$

(Die Formel ist nur ein gewichtetes Mitteln – nichts Magisches!)

Multi-Head Attention: Viele Experten gleichzeitig

Jeder Attention Head ist ein Experte für einen “Fachbereich”



Alle Heads lesen aus dem Residual Stream,
arbeiten parallel, und schreiben ihre Ergebnisse zurück.

Attention: Long-Distance Dependencies

Ein Wort am Anfang kann die Bedeutung
eines Wortes am Ende bestimmen:


Wer kam?



Woher?

Attention erlaubt **direkte Verbindungen** über beliebige Distanzen.
Ohne Attention müsste Information Wort für Wort weitergereicht werden.

Nebeneffekt: “nicht gut” $\neq$ “schlecht”




Attention bildet **gewichtete Summen** – es mittelt zwischen Punkten.
“nicht” verschiebt “gut” nur leicht. Es gibt keinen “spring zum Gegenteil”-Mechanismus.

Negation, Zählen, exakte Logik – alles schwierig für gewichtete Mittelwerte.

Was die Layer tun


Was macht ein Layer mit den Punkten?



Die Punkte werden **verschoben**. In den Verschiebungen finden die Berechnungen statt – nicht “Nähe” ist das Ziel.

Nach vielen Layern: “Katze” kodiert nicht mehr nur *Katze*, sondern **“die Katze die hier sitzt”** – den gesamten Kontext.

Spätere Layer: Immer abstrakter





Die genauen Grenzen sind fließend und modellabhängig.
Aber das Muster: **von konkret zu abstrakt** ist konsistent.

Next-Token-Prediction

Am Ende: Welches Wort kommt als nächstes?

Input: "Die flauschige ___"



Attention und Dense Layer haben die Bedeutungen des **gesamten bisherigen Kontextes** in diesen einen Vektor gemischt.


Sampling: Zufall und Kontrolle

Temperature:

- Niedrig: Fast immer Top-Wort
- Hoch: Auch Überraschungen

Top-K:

- Nur die besten K Wörter
- Rest wird ausgeschlossen



Beides steuert “kreativ” vs.
“zuverlässig”.

Die Black Box

Das große Geheimnis



Wir kennen jeden Baustein. Wir kennen jedes Gewicht.

Aber wir verstehen nicht, was die Gewichte zusammen bedeuten.

Wie ein Gehirn: Wir kennen die Neuronen, aber nicht die Gedanken.

Mechanistic Interpretability

Mechanistic Interpretability

Ein junges Forschungsfeld versucht,
die gelernten Algorithmen zu entschlüsseln.

Die Idee:


- Einzelne “Schaltkreise” finden
- Verstehen was wo gespeichert ist
- Algorithmen identifizieren

Stand heute:

- Ein verschwindend geringer Teil ist verstanden
- Aber: faszinierende Funde!
- Es funktioniert – wir sehen nur nicht warum

Die Weltkarte im Netzwerk

Städte-Embeddings aus einem LLM



Das Modell hat **nie eine Karte gesehen**. Nur Text.
Aber die effizienteste Art Entfernungen zu kodieren *ist* eine Karte.

Was wir wissen – und was nicht

Verstanden:

- Die Architektur (Bauplan)
- Einzelne einfache Schaltkreise
- Dass Struktur emergiert
- Dass es “irgendwie funktioniert”

Nicht verstanden:


- Was in den mittleren Layern passiert
- Warum Halluzinationen entstehen
- Ob es ein “Weltmodell” gibt
- Wie Reasoning wirklich funktioniert

Wir sehen, dass es funktioniert.

Wir verstehen einen verschwindend geringen Teil davon.

Zusammenfassung

Der komplette Weg



Erstaunlich einfache Bausteine. Erstaunlich komplexes Ergebnis.

Was wir mitnehmen

1. **Embedding Space:** Wörter sind Punkte – Bedeutung ist Geometrie
2. **Dense + ReLU:** Kann mit genug Neuronen alles berechnen
3. **Tokens:** KI liest in Silben-Stücken, nicht in Buchstaben
4. **Attention:** Verbindet Wörter über beliebige Distanzen
5. **Residual Stream:** Globales Notizbuch, in das alle Layer schreiben
6. **Vorhersage:** Immer nur das nächste Wort
7. **Black Box:** Wir verstehen fast nichts vom Innenleben – noch nicht

Danke!

Fragen?